

Analyse von Studienverläufen mit Process-Mining-Techniken

Rüdiger Buck-Emden · Franz-Dominik Dahmann

Eingegangen: 19. Dezember 2016 / Angenommen: 1. März 2018 / Online publiziert: 19. März 2018
© Springer Fachmedien Wiesbaden GmbH, ein Teil von Springer Nature 2018

Zusammenfassung Studenten an Hochschulen und Universitäten haben bei der Gestaltung ihrer Studienverläufe meistens viele Freiheitsgrade. Begrenzt werden diese Freiheiten durch das Curriculum, das bestimmte Rahmenbedingungen für den Studienverlauf einer Fachrichtung festlegt und Empfehlungen bzw. Vorgaben macht, welche Veranstaltungen in welchem Semester besucht werden sollen.

In der Praxis weichen viele Studenten von den Empfehlungen des Curriculums ab. Dies führt zu einer Vielzahl individueller Studienverläufe, von denen jeder einzelne mehr oder weniger erfolgreich sein kann (z.B. in Hinblick auf das Erreichen des angestrebten Abschlusses, auf die erzielte Abschlussnote oder auf die benötigte Studiendauer).

Für eine an erfolgreichen Studienverläufen orientierte Weiterentwicklung von Curricula und zugehörigen Studienberatungen fehlen den Verantwortlichen an Hochschulen und Universitäten nicht selten detaillierte Erkenntnisse über das konkrete Studienverhalten und über erfolgreiche bzw. weniger erfolgreiche Studienverlaufsmuster. Durch Process-Mining-Techniken wie Bubble-Chart-Analysen, Fuzzy Mining und Inductive Visual Mining können die Verantwortlichen Transparenz bei der Auswertung von Studienverläufen gewinnen und darauf aufbauend gezielte Maßnahmen einleiten.

Schlüsselwörter Blasendiagramm · Business Process Intelligence · Curriculum · Datenanalyse · Disco · Educational Data Mining · Educational Process Mining · Fuzzy Mining · Geschäftsprozess · Inductive Visual Mining · Process Mining · ProM · RapidMiner · Studenten · Studienverlauf

R. Buck-Emden (✉) · F.-D. Dahmann
Fachbereich Informatik, Hochschule Bonn-Rhein-Sieg, Grantham-Allee 20, 53757 Sankt Augustin, Deutschland
E-Mail: ruediger.buck-emden@h-brs.de

Analyzing Courses of University Studies by Using Process Mining Techniques

Abstract Students at universities usually enjoy a high level of freedom to shape their course of studies. Only the curriculum is the limit, which defines rules and suggests courses to be taken in certain semesters. In practice, many students deviate from these suggestions, leading to a plethora of individual schedules which may be more or less successful (with regards e.g. to achieved degree, final rates, and time to graduation). University officials in charge of evolving and enhancing curricula as well as student advisory services often do not have detailed knowledge regarding student's specific behavior as well as successful and less successful study schedules. Here process mining techniques like bubble chart analytics, fuzzy mining, and inductive visual mining can fill the gap and provide transparency as foundation for dedicated measures.

Keywords Bubble Chart · Business Process · Business Process Intelligence · Curriculum · Data Analytics · Disco · Educational Data Mining · Educational Process Mining · Fuzzy Mining · Inductive Visual Mining · Process Mining · ProM · RapidMiner · Student · Course of Studies

1 Einführung

Unter dem Begriff *Business Process Intelligence (BPI)* werden verschiedene Nutzungsformen von Business-Intelligence(BI)-Techniken zur Analyse von Geschäftsprozessen zusammengefasst (Grigori et al. 2004; Linden et al. 2010). Diese Disziplin hat in den vergangenen 15 Jahren erheblich an Bedeutung gewonnen (Bolt et al. 2015), bietet sie doch Unternehmen und Verwaltungen die Basis dafür, durch ein verbessertes Verständnis und eine kontinuierliche Weiterentwicklung der Geschäftsabläufe wirtschaftliche und operative Vorteile zu erlangen. Als eine wichtige BPI-Kategorie hat sich mittlerweile Process Mining etabliert (van der Aalst 2016). Process Mining steht als Oberbegriff für Verfahren zur Analyse von Geschäftsprozessen auf Basis von digitalen Spuren (Log- oder Protokolldaten), die Geschäftsprozessinstanzen bei ihrer Ausführung im System hinterlassen. Im Einzelnen kann man bei der praktischen Durchführung von Process Mining folgende Phasen unterscheiden: Extraktion/Bereitstellung der benötigten Log-Daten, Aufbereitung (Filterung, Bereinigung) der Log-Daten, Modellerstellung unter Verwendung des gewählten Process-Mining-Verfahren sowie die Ableitung von Erkenntnissen auf Basis des erstellten Modells (siehe Kap. 7).

Schon früh wurde auch im Bereich der Hochschulen und Universitäten unter den Bezeichnungen *Educational Data Mining (EDM)* und *Educational Process Mining (EPM)* über Möglichkeiten zur Verbesserung ausbildungsbezogener Abläufe durch Nutzung geeigneter BPI-Analyseverfahren nachgedacht (siehe z.B. Romero und Ventura 2007; Trčka et al. 2010; Cairns et al. 2015; Bogarín et al. 2017). Der hier vorliegenden Beitrag zeigt, dass Studienverläufe von Studenten an Hochschulen und Universitäten als eine spezielle Klasse von Geschäftsprozessen (oder präziser:

als Geschäftsprozessinstanzen oder Fälle, siehe Kap. 2) interpretiert werden können, und weist konkrete Wege auf, diese mit den Möglichkeiten des Process Minings zu analysieren. Auf Basis dieser Analysen können Verantwortliche an Hochschulen und Universitäten (z. B. Studiendekane, Curriculums-Planer und Studienberater) typische Studienverlaufsmuster erkennen, Bedürfnisse ihrer Studenten besser verstehen, Curricula adäquat weiterentwickeln und Studenten bei der Studienverlaufsplanung gezielt beraten.

2 Geschäftsprozesse

Unter einem Geschäftsprozess verstehen wir hier das allgemeine Konzept eines betrieblichen Ablaufs (z. B. „Auftragsabwicklung“). Geschäftsprozesse umfassen verschiedene Aktivitäten (z. B. „Auftrag erfassen“ und „Fertigungsauftrag erstellen“). Die konkrete Ausführung eines allgemeinen Geschäftsprozesses bezeichnet man als Fall (Case) oder auch Geschäftsprozessinstanz (z. B. „Auftragsabwicklung für Auftrag X vom Kunden A“). Die Ausführung einer bestimmten Aktivität innerhalb eines Falls (z. B. „Auftrag erfassen im Rahmen der Auftragsabwicklung für Auftrag X vom Kunden A“) korrespondiert mit einem zugehörigen Ereignis (Event), z. B. dem Start- oder Endereignis der Aktivität. Ereignisse, die mit derselben Aktivität verbunden sind (z. B. „Auftrag erfassen“ in unterschiedlichen Fällen), werden zu Ereignisklassen (Event Classes) zusammengefasst (Dumas und García-Bañuelos 2015). Jede Ereignisklasse wird in dem durch Process Mining erzeugten Prozessmodell eindeutig mit einem Aktivitätsknoten assoziiert (Günther und van der Aalst 2007). Gerichtete Kanten (Verbindungen) definieren im Prozessmodell eine partielle Ordnung auf der Menge der Aktivitätsknoten und drücken die zeitlich-logische Reihenfolge der Knoten aus. Ereignisse sind eindeutig identifizierbar und werden vom ausführenden System in gewisser Weise als Event-Log aufgezeichnet. Um den Verlauf einzelner Prozessinstanz mit Process Mining analysieren zu können, muss jedes Ereignis des Event-Logs einem konkreten Fall zuordenbar sein (siehe auch van der Aalst 2016).

3 Studienverläufe und Process Mining

Bei der Ausprägung ihrer Studienverläufe haben Studenten an Hochschulen und Universitäten in der Regel viele Freiheitsgrade. Begrenzt werden diese Freiheiten durch das Curriculum, das bestimmte Rahmenbedingungen für den Studienverlauf in einer Fachrichtung festlegt. So definiert das Curriculum z. B. Wahl- und Pflichtveranstaltungen und bestimmte einzuhaltende Regeln (etwa dass die Lehrveranstaltung A erst besucht werden darf, wenn zuvor die Prüfungen zu den Veranstaltungen B und C bestanden wurden). Zusätzlich liefert das Curriculum Empfehlungen, welche Veranstaltungen in welchem Semester besucht werden sollten.

In der Praxis weichen Studenten häufig von den Empfehlungen des Curriculums ab, z. B. weil diese Vorgaben nicht ihren individuellen Wünschen entsprechen, weil ihr bisher erworbener Kenntnisstand ihnen für bestimmte Lehrveranstaltungen noch

nicht ausreichend erscheint oder weil sie bestimmte Prüfungen noch nicht bestanden haben. Dies führt in der Praxis zu einer Vielzahl unterschiedlicher Studienverläufe, von denen jeder einzelne mehr oder weniger erfolgreich sein kann (z. B. in Hinblick auf das Erreichen des angestrebten Abschlusses, auf die erzielte Abschlussnote oder die benötigte Studiendauer).

Für eine an erfolgreichen Studienverläufen orientierte Weiterentwicklung der Curricula und der zugehörigen Studienberatungen fehlen den Verantwortlichen an Hochschulen und Universitäten nicht selten detaillierte Erkenntnisse über das konkrete Studienverhalten und über erfolgreiche bzw. weniger erfolgreiche Studienverlaufsmuster. Process-Mining-Techniken können hier Transparenz schaffen, denn diese Verfahren sind nicht nur auf die bereits erwähnten Geschäftsprozesse, sondern auch auf die Analyse von Studienverläufen anwendbar. Die erforderlichen Log-Daten lassen sich in diesem konkreten Anwendungsfall aus studienverlaufsrelevanten Ereignissen wie z. B. Immatrikulationen, Exmatrikulationen, Prüfungsanmeldungen, Prüfungswiederholungen oder Leistungsbenotungen ableiten.

Ganz allgemein können die Analyseziele von Process Mining in drei Kategorien aufgeteilt werden (van der Aalst 2016):

1. Entdecken (Discovery): Welches Prozessmodell liegt den beobachteten Log-Daten zugrunde?
2. Prüfen (Conformance): Entsprechen die beobachteten Abläufe (Log-Daten) einem vorgegebenen, bekannten Prozessmodell?
3. Verbessern (Enhancement): Wie kann ein bestehendes Prozessmodell auf Basis der beobachteten Log-Daten verbessert werden?

Diese drei Analysekatgorien lassen sich auch im Zusammenhang mit der Betrachtung von Studienverläufen wiederfinden: Entdecken des in der Praxis tatsächlich existierenden Studienverlaufsmodells, Prüfen von dessen Übereinstimmung mit dem durch das Curriculum empfohlenen Verlauf sowie Weiterentwicklung des Curriculums im Sinne einer gewünschten Zielfunktion (z. B. bezogen auf Durchschnittsnoten, Studiendauer, Durchsatz). Process-Mining-Analysen in Verbindung mit den in die jeweiligen Tools integrierten Visualisierungsmöglichkeiten (siehe nachfolgende Kapitel) stellen Studiendekanen, Curriculums-Planern und Studienberatern somit eine wertvolle Informationsbasis zur Verfügung, um z. B. Antworten auf die folgenden Fragen zu finden:

- Wie gut sind die Folge der Lehrveranstaltungen über die einzelnen Semester des Curriculums (Lehrplansemester) hinweg und die Zusammenstellung der Lehrveranstaltungen innerhalb eines Semesters auf die Bedürfnisse der Studenten abgestimmt?
- Welche Wege durch das Studium (Studienverläufe) sind bei den Studenten besonders populär, welche werden weniger oft verfolgt?
- Was unterscheidet die Studienverläufe erfolgreicher Studenten von weniger erfolgreichen?
- Welche Lehrveranstaltungen werden von erfolgreichen bzw. weniger erfolgreichen Studenten wann im Studienverlauf belegt bzw. gemieden?
- An welchen Lehrveranstaltungen scheitern Studenten häufig?

- Für welche Lehrveranstaltungen könnten zusätzliche, freiwillige Aufbauveranstaltungen, Vorkurse oder Tutorien hilfreich sein?
- Welche konkreten Empfehlungen sollen Studienberater Studenten in einer konkreten Studiensituation für den weiteren Studienverlauf geben?
- Welche Lehrveranstaltungen bringen Studenten letztendlich dazu, ihr Studium abzubrechen?

Nachfolgend geben wir zunächst einen kurzen Überblick zum Stand der Forschung, beschreiben anschließend die von uns eingesetzten Werkzeuge und Verfahren des Process Minings und stellen abschließend ein Vorgehensmodell zur Analyse von Studienverläufen mithilfe von Process Mining vor.

4 Stand der Forschung

Process Mining hat als allgemeine Disziplin zur Analyse von Geschäftsprozessen seit dem wegweisenden Artikel von van der Aalst und Weijters aus dem Jahre 2004 (van der Aalst und Weijters 2004) kontinuierlich an Aufmerksamkeit gewonnen. Eine umfassende Einführung in die Möglichkeiten von Process Mining gibt van der Aalst in seinem aktuellen Buch zum Thema (van der Aalst 2016). Praktische Anwendungsszenarien von Process Mining sind vielfältig und werden schwerpunktmäßig im Kontext betrieblicher Abläufe diskutiert (siehe z. B. Rischawe und Buck-Emden 2015). Für die Analyse von Studienverläufen an Hochschulen und Universitäten auf Basis von Process-Mining-Techniken existieren ebenfalls einige Arbeiten, die im Rahmen von Educational Data Mining und Educational Process Mining (Bogarín et al. 2017) diskutiert werden, z. B. von Trčka und Pechenizkiy (2009), Emond und Buffett (2015), Cairns et al. (2015) und Mukala et al. (2015). Unserem Vorgehen am nächsten kommen Trčka et al. (2010), Wang und Zaiane (2015) sowie Schulte et al. (2017), allerdings mit im Vergleich zu dem nachfolgend beschriebenen Vorgehen weniger umfassenden bzw. weniger detaillierten Ansätzen. So beschränken sich Trčka et al. (2010) auf die Bubble-Chart-Analyse zur Visualisierung von Prüfungsergebniskategorien auf der Ebene einzelner Studenten sowie auf Fuzzy Mining zur Untersuchung der Popularität einzelner Lehrveranstaltungen. Wang und Zaiane (2015) machen wie auch Schulte et al. (2017) keine spezifischen Angaben zu den von ihnen konkret eingesetzten Process-Mining-Verfahren.

5 Werkzeuge

Im Rahmen des in Kap. 7 vorgestellten Vorgehensmodells wurden von uns die folgenden Werkzeuge eingesetzt: Excel (Microsoft) für die Datenvorbereitung sowie Disco (Fluxicon), ProM (TU Eindhoven) und RapidMiner. Bis auf Microsofts Excel stehen alle genannten Tools für Forschungszwecke kostenfrei zur Verfügung.

5.1 Datenvorbereitung

Die Vorbereitung der zu analysierenden Studienverlaufsdaten wurde von uns mit Microsoft Excel durchgeführt, da im Excel-Dateiformat XLS oder XLSX aufbereitete Daten direkt von den nachfolgend aufgelisteten Analyse-Werkzeugen weiterverarbeitet werden können. Alternativ zu Excel sind auch andere Programme einsetzbar (z. B. Libre Office), sofern sie zumindest Ausgabedateien im CSV-Format (Comma-Separated Values) erzeugen können. Im Rahmen unserer Untersuchung erforderte lediglich ProM eine Konvertierung in das spezielle eXtensible-Event-Stream(XES)-Format (Process Mining Group 2016) nach IEEE (Institute of Electrical and Electronics Engineers). Diese Konvertierung kann z. B. einfach durch Einlesen der vorbereiteten Dateien in das Tool Disco (siehe Abschn. 5.4) und nachfolgenden Export im XES-Format durchgeführt werden.

5.2 RapidMiner

Der ursprünglich aus einem Forschungsprojekt an der TU Dortmund hervorgegangene, Java-basierte RapidMiner (Mierswa 2009) wird heute von der gleichnamigen Firma als Werkzeug für maschinelles Lernen und Data Mining angeboten. Im Rahmen unserer Untersuchung haben wir den RapidMiner Version 7.2 für die Bubble-Chart-Analyse (Erzeugung von Blasendiagrammen) eingesetzt (siehe Abschn. 6.1). Alternativ zum RapidMiner können auch beliebige andere Visualisierungswerkzeuge genutzt werden, sofern diese wie der RapidMiner Blasendiagramme mit mindestens vier Parametern (X- und Y-Koordinaten sowie Objektgröße und Objektfarbe) unterstützen. Wir haben uns aufgrund der einfachen Bedienbarkeit und der Verfügbarkeit als Open-Source-Software für den RapidMiner entschieden.

5.3 ProM

ProM ist ein umfassendes, kostenfreies, an der TU Eindhoven entwickeltes und auf der Programmiersprache Java basierendes Process-Mining-Framework (van Dongen et al. 2005). Durch Verwendung von Plug-Ins können verschiedenste Process-Mining-Verfahren eingesetzt werden. Im Rahmen dieser Untersuchung wurde ProM Version 6.5 in Verbindung mit dem Inductive Visual Miner (IvM, siehe Abschn. 6.3) genutzt. IvM steht ausschließlich als Plug-In für ProM zur Verfügung.

5.4 Disco

Disco ist eine komfortable, von der Firma Fluxicon entwickelte Process-Mining-Lösung (Günther and Rozinat 2012). Diese Software stellt eine Weiterentwicklung des im Rahmen von ProM für die Geschäftsprozessanalyse entwickelten Fuzzy-Mining-Ansatzes dar (siehe Abschn. 6.2) und zeichnet sich gegenüber ProM durch verbesserte Usability und eine ansprechende Visualisierung der Analyseergebnisse aus. Disco ist in der Lage, Excel-Dateien direkt einzulesen und, falls erforderlich, z. B. auch im XES-Format zu exportieren (z. B. für die Weiterverarbeitung mit ProM).

Von uns wurde Disco Version 1.9 eingesetzt. Disco steht für Hochschulen kostenfrei zur Verfügung.

6 Verfahren

Für die Analyse von Studienverläufen haben sich im Rahmen unserer Untersuchung besonders die nachfolgend skizzierten Verfahren Bubble-Chart-Analyse, Fuzzy Mining und Inductive Visual Mining als nützlich erwiesen, da diese eine schnelle Verarbeitung größerer Event-Logs ermöglichen und eine flexible, für die Analyse von Studienverläufen geeignete Visualisierung der Analyseergebnisse auf unterschiedlichen Detaillierungsniveaus bieten. Alternative Process-Mining-Verfahren wie z. B. der Alpha-Algorithmus (van der Aalst et al. 2004) und der Heuristic Miner (Weijters et al. 2006) haben dagegen Nachteile, wenn es wie in unserem Fall um die Analyse und Visualisierung wenig strukturierter Prozesse mit einer großen Anzahl feingranularer Ereignisse/Aktivitäten geht (siehe z. B. auch Gupta 2014; Bogarín et al. 2017). Bei größeren Event-Logs liefern letztgenannte Verfahren im schlechtesten Fall nur wenig verständliche Spaghetti-Prozessmodelle (siehe z. B. Günther und van der Aalst 2007; Jans et al. 2011; Bose et al. 2011; Cairns et al. 2015).

Bei den im Folgenden betrachteten Studienverläufen gehen wir beispielhaft von einem fiktiven, sechssemestrigen Studiengang aus, also von sechs im Curriculum vorgesehenen Lehrplansemestern. Studenten benötigen sechs oder mehr Fachsemester, um das Studium abzuschließen (sofern sie das Studium nicht vorher abbrechen).

Studienverläufe interpretieren wir als Folgen von Ereignissen, wobei jedes Ereignis mit einer Prüfung assoziiert ist. Prüfungen entsprechen somit den mit Ereignisklassen korrespondierenden Aktivitätsknoten in den erstellten Prozessmodellen. Studenten haben die Möglichkeit, sich, sofern sie die Voraussetzungen erfüllen, in jedem Fachsemester zu Prüfungen der verschiedenen Lehrplansemester anmelden. Sie können diese Prüfungen entweder bestehen oder nicht bestehen.

6.1 Bubble-Chart-Analyse

Bubble-Charts (Blasendiagramme) sind eine Variante der Scatter-Charts (Streudiagramme), die eine zweidimensionale Darstellung mehrdimensionaler Daten ermöglichen.

Im Rahmen der Studienverlaufsanalyse ist die Bubble-Chart-Analyse für eine überblicksartige Betrachtung des Studiums als Ganzes geeignet. Die von uns mit dem RapidMiner durchgeführte Bubble-Chart-Analyse liefert eine vierdimensionale Koordinatendarstellung: X- und Y-Achse sowie Größe und Farbe der in das Koordinatenkreuz eingetragenen Blasen. Die X-Achse bezeichnet den Zeitverlauf (konkret in Abb. 1: den Verlauf der ersten sechs Fachsemester), die Y-Achse die Prüfungen zu den einzelnen Lehrveranstaltungen. Die Blasen im Koordinatensystem repräsentieren einzelne Prüfungen. Ihre Farbe kennzeichnet die Durchfallquote und ihre Größe die Anzahl der teilnehmenden Studenten. Im Idealfall ergibt sich daraus das in Abb. 1 beispielhaft gezeigte Muster mit den über sechs Lehrplansemester verteil-




Abb. 1 Beispielhafter Idealfall der Bubble-Chart-Analyse für Studienverläufe


ten Lehrveranstaltungen V_1_1 bis V_6_4. Lehrplansemester und Fachsemester der einzelnen Prüfungen sind in diesem Fall identisch.

Im besten Fall ist die volle Kapazität der Studienplätze zu Beginn des Studiums mit Studenten ausgelastet und alle Studenten erbringen alle Prüfungsleistungen in der Regelzeit und in den vom Curriculum vorgesehenen Lehrplansemestern, ohne in Prüfungen durchzufallen. Dadurch ergibt sich das in Abb. 1 dargestellte ideale Stufenmuster. In der Realität zeigen sich allerdings in der Regel Abweichungen vom idealen Verlaufsmuster, so dass nicht mehr alle Blasen die gleiche Farbe oder Größe haben. Außerdem können zu einzelnen Prüfungen mehrere Blasen in verschiedenen Fachsemestern auftreten. Dieser Fall ist z.B. gegeben, wenn Studenten in einem Semester eine Prüfung zu einer Veranstaltung nicht bestanden haben und diese Prüfung in einem der Folgesemester nachholen. Je größer die tatsächliche Abweichung von dem in Abb. 1 dargestellten Muster ist, desto mehr Studenten haben sich nicht an das empfohlene Regel-Curriculum gehalten.

6.2 Fuzzy Mining

Die von uns eingesetzte Fuzzy-Mining-Geschäftsprozessanalyse steht ausschließlich mit ProM und Disco zur Verfügung. Der Name dieses Process-Mining-Verfahrens hat seinen Ursprung nicht darin, dass der Algorithmus ungenau (fuzzy) ist oder auf Fuzzy Logic (Zadeh 1988) basiert, sondern weist darauf hin, dass einzelne Ereignisklassen je nach gewünschtem Detaillierungsgrad des zu erzeugenden Prozessmodells flexibel zu größeren Einheiten (Clustern) zusammengefasst werden können (Bannert et al. 2014). Gedanklich baut der Fuzzy-Mining-Algorithmus auf der Landkarten-Metapher auf und unterstützt dementsprechend variable Kartenmaßstäbe/Detaillierungsniveaus (Günther und van der Aalst 2007; Bose et al. 2011). Dadurch kann ein anfangs sehr umfangreiches Modell interaktiv auf ein vereinfachtes Modell verdichtet werden, welches sich nur noch auf die für den gewählten Detaillierungsgrad wesentlichen Aspekte beschränkt. Hierfür nutzt der Algorithmus die Metriken der Signifikanz und der Korrelation. Signifikanz misst, basierend auf Häufigkeiten, die auf das gewünschte Detaillierungsniveau des zu erzeugenden Modells bezogene Wichtigkeit einzelner Ereignisklassen (Aktivitäten) und Kanten. Korrelation drückt aus, wie eng die Beziehung zweier aufeinanderfolgender Ereignisse ist. Beispielsweise wird die Korrelation zwischen zwei Ereignissen, die von derselben Person ausgelöst werden, als höher eingestuft als die Korrelation zwischen Ereignissen mit unterschiedlichen auslösenden Personen. Bei hoher Korrelation werden Ereignisklassen (Aktivitäten), die auf Grund geringer Signifikanz in einem Modell mit geringem Detaillierungsgrad nicht berücksichtigt werden würden, zu Clustern zusammengefasst und finden so trotzdem Eingang in das erstellte Prozessmodell. Mithilfe beider Metriken unterstützt der Fuzzy-Mining-Algorithmus somit Benutzer bei der interaktiven Modellerzeugung auf der gewünschten Detaillierungsstufe (Günther und van der Aalst 2007). Der wesentliche Vorteil des Fuzzy-Mining-Verfahrens liegt somit darin, dass es auch bei komplexen Abläufen, die viele und miteinander vernetzte Aktivitäten umfassen, übersichtliche Prozessmodelle auf dem gewünschten Detaillierungsniveau erzeugen kann und so z.B. auch die Möglichkeit bietet, Hauptströmungen innerhalb der Prozesse (z.B. Mainstreams der Studienverläufe)

Abb. 2 Fuzzy Mining einer Kohorte zu Lehrveranstaltung/Prüfung V_1_6



grafisch darzustellen (Jans et al. 2011). Limitationen hat Fuzzy Mining allerdings bei der Darstellung parallel ablaufender Aktivitäten, da gängige Prozessmuster wie Split und Join nicht unterstützt werden (Günther und van der Aalst 2007).

Zur Visualisierung der erzeugten Prozessmodelle verwendet das Fuzzy-Mining-Verfahren Rechtecke mit abgerundeten Ecken für Aktivitätsknoten sowie gerichtete Kanten zwischen Aktivitätsknoten als grafische Kennzeichnung der Reihenfolge, die in unserem Fall die Studien- bzw. Prüfungsverläufe beschreibt.

Die vom Benutzer interaktiv durchzuführende Fuzzy-Mining-Analyse besteht aus drei Schritten. Der erste Schritt ist die Konfliktlösung, wenn sich zwischen zwei ermittelten Aktivitätsknoten A und B sowohl Kanten A->B und B->A befinden (Günther und van der Aalst 2007), der zweite das Kanten-Filtern und der dritte Schritt ist die Knotenaggregation und -abstraktion. Die ersten beiden Schritte dienen dazu, Kanten zwischen Aktivitätsknoten, die auf dem jeweils eingestellten Detaillierungsniveau keine Relevanz haben, zu entfernen. Im dritten Schritt werden dann, je nach gewünschtem Detaillierungsgrad, Aktivitätsknoten zu Clustern zusammengefasst oder ebenfalls entfernt.

Fuzzy Mining hat sich im Rahmen unserer Studienverlaufsanalyse als geeignet für die Detailbetrachtung einzelner Lehrveranstaltungen (oder genauer: der zugehörigen Prüfungen) erwiesen, da genau abgebildet werden kann, wie Studenten sich bezüglich einer speziellen Prüfung verhalten. So wird z.B. schnell ersichtlich, ob Prüfungsteilnehmer an Verbesserungsversuchen interessiert sind oder nicht. Abb. 2 zeigt beispielhaft die Lehrveranstaltung V_1_6 mit den von einem Studentengang (einer Kohorte) im ersten, zweiten und dritten Versuch bestandenen (BE) bzw. nicht bestandenen (NB) Prüfungen. Wiederholungsprüfungen können in diesem Zusammenhang in unterschiedlichen Fachsemestern stattfinden (siehe die Erläuterungen zur Bubble-Chart-Analyse in Abschn. 6.1) und schließen auch durchgeführ-

te Verbesserungsversuche ein (in Abb. 2 gab es z. B. vier Verbesserungsversuche ($2 + 2$), von denen zwei nicht bestanden wurden).

6.3 Inductive Visual Mining

Inductive Visual Mining (IvM) unterstützt wie das Fuzzy Mining die interaktive Erzeugung von Prozessmodellen, kann aber auch sehr gut mithilfe gängiger Prozessmuster (Split, Join) parallel ablaufende Aktivitäten darstellen. Zusätzlich bietet Inductive Visual Mining die Möglichkeit zur Anzeige von Performance-Kennzahlen, zur Animation von Prozessinstanzen und zum direkten Abgleich des erzeugten Prozessmodells mit dem zugrundeliegenden Event-Log (Leemans et al. 2013, 2014; Leemans 2017).

Der Inductive Visual Miner basiert auf Process Trees (Leemans et al. 2013) und vermeidet dadurch mögliche Anomalien (z. B. Deadlocks) innerhalb der erzeugten Prozessmodelle (van der Aalst 2016). Auch umfangreiche Event-Logs können vom Inductive Visual Miner durch Aufteilung in kleinere Logs und anschließende Erzeugung von Teilprozessmodellen ausgewertet werden. Diese Teilprozessmodelle werden anschließend über mehrere Iterationen zu einem Gesamtmodell zusammengefügt (Divide-and-Conquer-Ansatz). Durch Filterung von als nicht relevant erachteten Aktivitäten und Kanten sind außerdem unterschiedliche Detaillierungsniveaus möglich.

Wie bei Fuzzy Mining stellen beim Inductive Visual Mining Rechtecke mit abgerundeten Ecken Aktivitätsknoten und gerichtete Kanten die Reihenfolge, in der Aktivität ausgeführt wurden, dar (siehe Abb. 3). Ferner gibt es für Kanten UND-Splits und -Joins (Raute mit Plus-Zeichen) sowie ODER-Splits und -Joins (kleiner Kreis) sowie gelbe Kreisobjekte für einzelne Prozessinstanzen (in Abb. 3 nicht dargestellt). Rot gestrichelte Linien kennzeichnen durch das gewählte Detaillierungsniveau begründete Abweichungen (Deviations) zwischen dem in Blau dargestellten, erzeugten Modell und den tatsächlich aufgezeichneten Log-Daten. Bei den in Abb. 3 dargestellten Abweichungen handelt es sich um sogenannte Model-Moves, d. h. um die Kennzeichnung von Aktivitäten im Modell, die nicht von allen Prozessinstanzen ausgeführt wurden. Außerdem sind Log-Moves möglich (hier nicht dargestellte, selbst-referenzierende, rot gestrichelte Linien), die ausdrücken, dass einige Aktivitäten, die in den Logs einzelner Prozessinstanzen registriert sind, im Modell nicht wiedergegeben sind (siehe Leemans et al. 2014).

Inductive Visual Mining ermöglicht eine detaillierte Auswertung von Folgen von Prüfungen, also von Prüfungsverläufen, bis auf die Ebene einzelner Studenten. Abb. 3 zeigt beispielsweise für eine Kohorte mit 72 Studenten, wie viele von ihnen bis zum sechsten Fachsemester die einzelnen Prüfungen des zweiten Lehrplansemesters absolviert haben, wie viele sich für einzelne Prüfungen nicht angemeldet haben (obwohl diese laut Curriculum vorgesehen waren, rote gestrichelte Linie), wie viele Prüfungswiederholungen es gab (Rückpfeile) und wie viele Studenten einen größeren Block, bestehend aus mehreren Prüfungen, komplett umgangen haben. Berücksichtigt werden dabei alle Studenten, die bis zum sechsten Fachsemester mindestens eine Prüfung des zweiten Lehrplansemesters abgelegt haben.




Abb. 3 IvM-Analyse der Lehrveranstaltungen/Prüfungen des zweiten Lehrplansemesters für eine Kohorte (Rückblick aus dem sechsten Fachsemester)

7 Vorgehensmodell zur Studienverlaufsanalyse mit Process Mining

Für Hochschul- und Universitätsmitarbeiter, die die Studienverläufe ihrer Studenten eigenständig mithilfe von Process Mining analysieren wollen, geben wir nachfolgend ein leicht nachvollziehbares Vorgehensmodell an. Dieses Vorgehensmodell besteht, wie bereits in Kap. 1 im Zusammenhang mit der Einführung von Process Mining ausgeführt, aus den vier Phasen *Datenbereitstellung*, *Datenaufbereitung*, *Anwendung der Process-Mining-Verfahren* und *Ergebnisauswertung*.

7.1 Datenbereitstellung

Studienverlaufsdaten werden in dem hier betrachteten Vorgehensmodell durch Ereignisse repräsentiert. Ereignisse können z. B. das Bestehen oder das Nicht-Bestehen einer Prüfung sein. Erfahrungsgemäß ist für aussagekräftige Analyseergebnisse ein Ereignis-Log mit einer mindestens vierstelligen Anzahl an Ereignissen erforderlich.

Das hier beschriebene Vorgehensmodell geht davon aus, dass die auszuwertenden Studienverlaufsdaten in zwei Tabellen (XSL-, XSLX- oder CSV-Format, siehe Abschn. 5.1) gemäß dem nachfolgend angegebenen Schema vorliegen. Die erste Tabelle wird für Fuzzy-Mining- und Inductive-Visual-Mining-Analysen benötigt, die zweite für Bubble-Chart-Analysen. Das für den Inductive Visual Miner in ProM benötigte XES-Eingabeformat erzeugen wir komfortabel mithilfe des Tools Disco (siehe Abschn. 5.4).

Tabelle 1: Die erste Tabelle enthält zu jedem Ereignis die folgenden Spalten:

- *Matrikelnummer*
Die Matrikelnummer muss zu jedem Ereignis aufgeführt werden.
- *Veranstaltung*
Die Veranstaltungs- bzw. Prüfungsbezeichnung muss zu jedem Ereignis aufgeführt werden. Außerdem sollte das Lehrplansemester, in dem diese Prüfung gemäß Curriculum zu absolvieren ist, angegeben werden.
- *Semester*
Das Semester ist das individuelle Fachsemester, in dem der Student das Ereignis erzeugt hat. Das konkrete Jahr, in dem er eine Prüfung absolviert, ist dagegen nicht relevant.
- *Ergebnis*
Das Ergebnis sagt aus, ob ein Student eine Prüfung erfolgreich (BE) oder nicht erfolgreich (NB) absolviert hat.

Zusätzlich zu den notwendigen Spalten ist es sinnvoll, weitere Spalten einzuführen, um weitere Analysen zu ermöglichen.

- *Versuch*
Versuch gibt an, ob ein Student eine Prüfung zum ersten Mal durchführt oder ob er sie bereits häufiger belegt hat.
- *Exmatrikulation*
Unter Exmatrikulation wird festgehalten, ob der Student, der ein Ereignis erzeugt, noch in der Hochschule immatrikuliert oder bereits exmatrikuliert ist.
- *Exmatrikulationsgrund*
Um weiterführende Informationen zu der Exmatrikulation zu erhalten, kann es sinnvoll sein, auch den Exmatrikulationsgrund aufzuführen. Hier bietet es sich an, Kategorien zu bilden.

Tabelle 2: Die zweite Tabelle (siehe Abb. 4) nimmt aggregierte Daten für die Bubble-Chart-Analysen auf. Basierend auf Tabelle 1 wird pro Prüfung und Fachsemester eine Zeile mit folgenden Spalten generiert: Veranstaltungs-/Prüfungsbezeichnung, das betrachtete Fachsemester, die Anzahl Studenten, die die Prüfung in die-

Veranstaltung	Semester	Anzahl	Durchfallrate	Durchgefallene	Bestandene
V_1_1	1	66	0,00	0	66
V_1_2	1	20	45,00	9	11
V_1_3	1	75	8,00	6	69
V_1_4	1	44	59,09	26	18
V_1_5	1	73	26,03	19	54
V_1_6	1	61	86,89	53	8
...	...	...	...	...	...

Abb. 4 Input-Daten (Ausschnitt) für die Bubble-Chart-Analyse einer Kohorte (Rückblick aus dem sechsten Fachsemester)

sem Fachsemester bestanden bzw. nicht bestanden haben, sowie die Durchfallrate (in %).

7.2 Datenaufbereitung

Vor der Ausführung der einzelnen Process-Mining-Verfahren kann es notwendig sein, die in den Tabellen 1 und 2 vorhandenen Daten von inhaltlichen und formalen Fehlern zu bereinigen. Falls zum Beispiel Ereignisse im 0. Semester aufgeführt sind, so sind diese zu löschen bzw. zu korrigieren. Entsprechendes gilt, wenn in einem Studiengang Studenten z. B. parallel nach unterschiedlichen Prüfungsordnungen (alt/neu) studieren. In diesem Fall muss, um die Vergleichbarkeit sicherzustellen, eine bestimmte Version herausgefiltert werden.

7.3 Anwendung der Process-Mining-Verfahren

7.3.1 Bubble-Chart-Analyse

Für die Bubble-Chart-Analyse sind die Daten wie in Abb. 4 gezeigt aufzubereiten (siehe Abschn. 6.1 und 7.1).

Der RapidMiner kann die Tabelle aus Abb. 4 (Tabelle 2) mithilfe der Funktion *Read Excel* (im Fall einer XLS bzw. XLSX Datei) oder *Read CSV* (im Fall einer CSV Datei) importieren. Unter dem RapidMiner-Reiter *Advanced Charts* ist es dann möglich, das Blasendiagramm entsprechend zu konfigurieren. Der *Domain Dimension* wird das Fachsemester der Prüfungskandidaten zugeordnet, der *Color Dimension* die Durchfallrate, der *Size Dimension* die Anzahl und der *Nominal Axis* die Veranstaltungs-/Prüfungsbezeichnung. Zusätzlich kann bei Bedarf unter dem Reiter *Size Dimension* ein *Lower Filter* z. B. von 5 gewählt werden, um das Ergebnis visuell auf das gewünschte Detaillierungsniveau einzustellen. Prüfungen, die von weniger als fünf Studenten belegt wurden, werden bei dieser Einstellung in der Analyse nicht berücksichtigt. Nach Einstellung des Farbschemas liefert das Programm dann für die ersten sechs Fachsemester (X-Achse) eines beispielhaften Curriculum (sechs Lehrplansemester auf der Y-Achse) das in Abb. 5 wiedergegebene Ergebnis.




Abb. 5 Bubble-Chart-Analyse der ersten sechs Fachsemester einer Kohorte für ein beispielhaftes Curriculum (sechs Lehrpläne-semester)

7.3.2 Fuzzy Mining

Für die Fuzzy-Mining-Analyse mit Disco müssen zunächst die Daten aus Tabelle 1 in das Programm eingelesen werden. Disco bietet dazu eine komfortable Import-Funktion, mit der auch die Semantik der einzelnen Spalten (Activity, Time, Case¹) festgelegt werden kann. Eine Activity definieren wir in unserem Fall als Kombination aus Veranstaltung/Prüfung, Ergebnis und Versuch. Die Matrikelnummer bezeichnet den einzelnen Case (Fall, Prozessinstanz) und das Fachsemester den Zeitpunkt (Time) der Prüfung. Auf Basis dieser Festlegungen kann ein initiales Prozessmodell über alle Activities und Cases gebildet werden. Da wir hier eine einzelne Veranstaltung/Prüfung untersuchen, werden anschließend über einen Filter diejenigen Activities selektiert, die sich ausschließlich auf die ausgewählte Veranstaltung/Prüfung beziehen.

7.3.3 Inductive Visual Mining

Auch für die Inductive-Visual-Mining-Analyse mit ProM sind einige vorbereitende Schritte erforderlich. Zunächst werden die Daten aus Tabelle 1 in Disco importiert und dort die Semantik der einzelnen Spalten festgelegt. Als Activity definieren wir hier die Veranstaltung/Prüfung², als Time das Fachsemester und als Case-Bezeichner die Matrikelnummer. Die so parametrisierten Daten werden nun als ProM-kompatible XES-Datei exportiert und in ProM geladen, wo anschließend mit dem Inductive Visual Miner das gewünschte Prozessmodell erzeugt wird. Dabei lässt sich z.B. die Wiedergabe von Abweichungen (Deviations) oder der Detaillierungsgrad der Darstellung (Prozentsatz der angezeigten Kanten und Knoten) einstellen.

7.4 Ergebnisauswertung

7.4.1 Bubble-Chart-Analyse

Die Bubble-Chart-Analyse verschafft den Verantwortlichen an Hochschulen und Universitäten (Studiendekanen, Curriculums-Planern, Studienberatern etc.) eine grafisch aufbereitete und schnell zu erfassende Datengrundlage, wenn es um die Betrachtung von Studienverläufen als Ganzes geht. Abb. 5 deutet z.B. darauf hin, dass sich sehr viele Studenten nicht an das vorgegebene Regel-Curriculum gehalten haben. Ferner ist zu erkennen, dass vier von sechs Prüfungen des ersten Semesters eine Durchfallquote von mindestens 25 % haben, während die Durchfallquote bei der Mehrzahl der Prüfungen in den zwei folgenden Semestern unter 25 % liegt. Im vierten und fünften Semester gibt es wieder eine recht hohe Anzahl an Prüfungen mit Durchfallraten über 25 %. Dies könnte z. B. ein Indikator für die Notwendigkeit von gezielten Fördermaßnahmen im ersten, vierten und fünften Semester sein.

¹ Activity, Time und Case sind vom Tool Disco vorgegebene Bezeichnungen.

² Bei IvM bezieht sich eine Activity auf eine konkrete Veranstaltung/Prüfung, während eine Activity beim Fuzzy Mining eine Kombination aus Veranstaltung/Prüfung, Ergebnis und Versuch darstellt.

Auffällig ist die Durchfallquote der Prüfung V1_6 im ersten Lehrplansemester (zwischen 75 und 100 %). Außerdem fällt im ersten Semester auf, dass die Prüfungen zu V_1_1, V_1_3 und V_1_5 besonders viele Teilnehmer aufweisen, während die Prüfungen zu V_1_2 und V_1_4 nur sehr wenig gewählt wurden. Vergleicht man dies nun mit den Veranstaltungen des zweiten Semesters, so fällt auf, dass dort nur eine Veranstaltung eine Durchfallquote höher als 25 % hat. Dies könnte z. B. bedeuten, dass die Prüfungen/Veranstaltungen des zweiten Semesters zu einfach waren oder dass die schlecht ausgefallenen Prüfungen/Veranstaltung zu schwer oder nicht ausreichend vorbereitet waren. Außerdem könnte man z. B. die Möglichkeit untersuchen, eine schwere Veranstaltung des ersten Semesters in das zweite zu verlegen, um die Schwierigkeitsgrade über die Lehrplansemester auszugleichen. Ohne grafische Aufbereitung würde dieser Zusammenhang unter Umständen gar nicht auffallen, da eine Durchfallquote von 25 % im Vergleich zu den Durchfallquoten in den anderen Semestern nicht besonders hoch liegt.

Die Ursachen für die ermittelten Ergebnisse können vielfältig sein und müssen im konkreten Einzelfall inhaltlich genauer untersucht werden. Mögliche Ursachen für schlechte Prüfungsergebnisse sind z. B.: Prüfungen zu schwer, fachliche Grundlagen nicht ausreichend gelegt, falsche Erwartungshaltung bzgl. der Inhalte des Studium, Unwissen der Studenten über notwendige Voraussetzungen, Überlastung der Studenten durch parallele Veranstaltungen etc. Bevor gezielte Maßnahmen ergriffen werden können, ist daher ergänzend eine fachliche Untersuchung der Ursachen der durch Process Mining identifizierten Problemfelder erforderlich.

7.4.2 Fuzzy-Mining

Da die Veranstaltung V_1_6 in der Bubble-Chart-Analyse eine hohe Durchfallquote hatte, bietet es sich an, diese mithilfe von Fuzzy Mining näher zu analysieren. In Abb. 2 lässt sich ablesen, wie viele Studenten die Prüfung im Erstversuch bestanden haben und wie viele durchgefallen sind. Ferner ist zu sehen, wie viele Studenten die Prüfung bereits ein zweites Mal absolviert haben und bei wie vielen Studenten die Prüfung noch offen ist. So ist erkennbar, dass 29 ($=23 + 8 - 2$) Studenten die Prüfung noch ablegen müssen, während 40 ($=14 + 26 - 2 + 2$) Studenten die Prüfung bereits bestanden haben. Es wird deutlich, dass nur etwa zwei Drittel der Studenten, die die Prüfung im Erstversuch nicht bestehen, diese im Zweitversuch bestehen.

Ein weiterer Ansatz zur Fuzzy-Mining-Analyse von Prüfungsergebnissen wäre z. B. eine vergleichende Selektion von Regelstudent und Nicht-Regelstudenten, um so spezifische Merkmale des Prüfungsverhaltens beider Gruppen zu erkennen. Weiter ließe sich diese Analyse z. B. auch auf Abbrecher fokussieren, um ggf. spezielle Handlungsbedarfe (z. B. die Notwendigkeit zusätzliche Fördermaßnahmen) zu erkennen.

7.4.3 Inductive Visual Mining

Abb. 3 zeigt die Prüfungen des zweiten Lehrplansemesters. Im Beobachtungszeitraum von sechs Semestern haben insgesamt 72 Studenten mindestens eine Prüfung des zweiten Fachsemesters abgelegt. Von diesen 72 Studenten haben 3 weder V_2_2

noch V_2_3 und V_2_5 absolviert. Dies impliziert, dass diese Studenten diese Prüfungen auf einen späteren Zeitpunkt des Studiums verschoben haben, was ihren Studienerfolg auf Grund fehlender Grundlagen für Folgeveranstaltungen unter Umständen gefährdet. Ferner wird deutlich, dass insgesamt 26 (23+3) Studenten die Veranstaltung V_2_3 nicht absolviert haben. Dies lässt vermuten, dass die Prüfung zu V_2_3 eine der schwersten des zweiten Lehrplansemesters ist, insbesondere dann, wenn man sie mit der Prüfung V_2_4 vergleicht, die 69 Studenten absolviert haben. Auf Basis dieser Beobachtungen könnten Curriculums-Planer geeignete Maßnahmen einleiten, z.B. Förderangebote entwickeln oder die Zugangsvoraussetzungen für Folgeveranstaltungen von V_2_3 verschärfen.

So wie beim Fuzzy Mining wäre es auch beim Inductive Visual Mining möglich, Vergleiche zwischen Abbrechern, Regelstudenten und den übrigen aktiven Studenten durchzuführen, um Muster und Unterschiede beim Prüfungsverhalten der einzelnen Gruppen zu erkennen und daraus gegebenenfalls, basierend auf ergänzenden fachlichen Untersuchungen, geeignete Maßnahmen abzuleiten.

8 Zusammenfassung und Fazit

Process Mining zeichnet sich durch die Möglichkeit zur Erstellung von Prozessmodellen auf Basis von Event-Logs aus. Wir haben gezeigt, wie die heute vornehmlich aus dem Bereich der Geschäftsanwendungen bekannten Process-Mining-Techniken auch zur grafischen Analyse von Studienverläufen genutzt werden können.

Die Bubble-Chart-Analyse erlaubt eine leicht verständliche, grafische Darstellung des Studiums als Ganzes. Die Analyse kann aufzeigen, welche Veranstaltungen die Studenten in welchen Fachsemestern absolvieren und wie viele der Studenten bestimmte Prüfungen bestanden bzw. nicht bestanden haben. Hieraus sind bei Bedarf und in Verbindung mit ergänzenden fachlichen Untersuchungen Maßnahmen zur Weiterentwicklung des Curriculums, zur Verbesserung des Beratungsangebots, zur Anpassung des Anforderungsniveaus von Lehrveranstaltungen und Prüfungen sowie zur Bereitstellung von zusätzlichen Fördermaßnahmen ableitbar.

Mit der Fuzzy-Mining-Analyse ist es möglich, einzelne Veranstaltungen bzw. Prüfungen im Detail zu untersuchen. Dies betrifft z.B. das Belegungsverhalten der Studenten für einzelne Veranstaltungen/Prüfungen. So kann festgestellt werden, wie viele von ihnen nach dem Erstversuch einen Zweitversuch gemacht und wie viele die Veranstaltung nach einem Fehlversuch erstmal auf einen späteren Zeitpunkt verschoben haben. Weiter lässt sich durch eine Analyse der Verbesserungsversuche erkennen, ob Studenten eher zufrieden oder unzufrieden mit ihren Noten sind (und unter Umständen, bei entsprechender Förderung, bereit wären, mehr zu leisten). Die durch Fuzzy Mining erlangten Erkenntnisse ermöglichen es, speziell zugeschnittene Ausbildungspakete für bestimmte Studentengruppen zu konzipieren. Beispielsweise kann der Gruppe, die in zwei aufeinanderfolgenden Semestern eine Prüfung nicht bestanden hat, von den Dozenten spezielles Übungsmaterial bereitgestellt werden, um ihre Erfolgchancen zu verbessern.

Die Inductive-Visual-Mining-Analyse ist ein geeignetes Werkzeug für die Untersuchung ganzer Lehrplansemester. Mit ihr kann z.B. festgestellt werden, wie viele Studenten einzelne Prüfungen absolviert haben und welche Prüfungen gerne auf spätere Semester verschoben wurden. Erweitert man die Analyse derart, dass man sie für jede einzelne Kohorte durchführt, können auch zeitliche Veränderungen der Prüfungsbelegungsmuster erkannt und, in Kombination mit weiteren fachlichen Analysen, möglichen Ursachen zugeordnet werden (z.B. Änderungen am Veranstaltungs- und Prüfungsstoff, Änderungen der Prüfungsordnung, Einführung von Zwischentests etc.). So lassen sich anhand konkreter Analysedaten auch Aussagen über die Effektivität getroffener Maßnahmen ableiten.

Die verwendeten Process-Mining-Techniken mit ihren grafischen Darstellungsmöglichkeiten eröffnen den Verantwortlichen an Hochschulen und Universitäten tiefergehende Einblicke in das Studien- und Prüfungsverhalten ihrer Studenten. Probleme innerhalb des Curriculums können frühzeitig entdeckt und, nach ergänzender fachlicher Ursachenanalyse, durch geeignete Maßnahmen behoben werden.

Literatur

- van der Aalst W (2016) Process mining. Springer, Heidelberg New York
- van der Aalst W, Weijters A (2004) Process mining: a research agenda. *Comput Ind* 53(3):231–244
- van der Aalst W, Weijters A, Maruster L (2004) Workflow mining: discovering process models from event logs. *IEEE Trans Knowl Data Eng* 16(9):1128–1142
- Bannert M, Reimann P, Sonnenberg C (2014) Process mining techniques for analysing patterns and strategies in students' self-regulated learning. *Metacogn Learn* 9(2):161–185
- Bogarín A, Cerezo R, Romero C (2017) A survey on educational process mining. *Wiley interdisciplinary reviews: data mining and knowledge discovery*, S 1–17
- Bolt A, de Leoni M, van der Aalst W, Gorissen P (2015) Business process reporting using process mining, analytic workflows and process cubes: a case study in education. In: *International symposium on data-driven process discovery and analysis*, S 28–53
- Bose R, Verbeek E, van der Aalst W (2011) Discovering hierarchical process models using proM. *CAiSE Forum* 107:33–48
- Cairns AH, Gueni B, Fhima M, Cairns A, David S, Khelifa N (2015) Process mining in the education domain. *Int J Adv Intell Sys* 8(1):219–232
- van Dongen B, de Medeiros A, Verbeek H, Weijters A, van der Aalst W (2005) The proM framework: a new era in process mining tool support. *Proc. 26th Int. Conf. On Applications and Theory of Petri Nets (ICATPN 2005)*, Miami, S 444–454
- Dumas M, García-Bañuelos L (2015) Process mining reloaded: event structures as a unified representation of process models and event logs. *Proc. International Conference on Applications and Theory of Petri Nets and Concurrency*, S 33–48
- Emond B, Buffett S (2015) Analyzing student inquiry data using process discovery and sequence classification. *Proc. 8th International Conference on Educational Data Mining*, Madrid, S 412–415
- Grigori D, Casati F, Castellanos M, Dayal U, Sayal M, Shan MC (2004) Business process intelligence. *Comput Ind* 53(3):321–343
- Günther C, van der Aalst W (2007) Fuzzy mining – adaptive process simplification based on multi-perspective metrics. *Proc. 5th Int. Conf. on Business Process Management*, Brisbane. *Lecture Notes in Computer Science*, Vol 4714. Springer, Berlin, Heidelberg, S 328–343
- Günther C, Rozinat A (2012) Disco: discover your processes. *10th Int. Conf. On Business Process Management (BPM 2012)*, Tallinn, S 40–44 (BPM (Demos))
- Gupta E (2014) Process mining – a comparative study. *Int J Adv Res Comput Commun Eng* 3(11):8594–8598
- Jans M, van der Werf J, Lybaert N, Vanhoof K (2011) A business process mining application for internal transaction fraud mitigation. *Expert Syst Appl* 38(10):13351–13359
- Leemans S (2017) Inductive visual miner manual. www.leemans.ch/publications/ivm.pdf. Zugegriffen: 22. Dez. 2017

- Leemans S, Fahland D, van der Aalst W (2013) Discovering block-structured process models from event logs containing infrequent behaviour. *Proc. 11th Int. Conf. on Business Process Management*, Beijing, S 66–78
- Leemans S, Fahland D, van der Aalst W (2014) Exploring processes and deviations. *Proc. 12th Int. Conf. on Business Process Management (BPM 2014)*, Eindhoven. Springer, Cham, S 304–316
- Linden M, Felden C, Chamoni P (2010) Dimensions of business process intelligence. *Business Process Management Workshops (BPM 2010)*, S 208–213
- Mierswa I (2009) Open source data mining mit rapidminer. *Künstliche Intell* 2/2009:62–63
- Mukala P, Buijs J, van der Aalst W (2015) Exploring students' learning behaviour in MOOCs using process mining techniques. Eindhoven. BPM Center Report BPM-15-10. BPMCenter.org, Eindhoven
- Process Mining Group (2016) XES (eXtensible Event Stream). <http://www.processmining.org/logs/xes>. Zugegriffen: 27. Nov. 2016
- Rischawe R, Buck-Emden R (2015) Process-Mining in der Assekuranz. *HMD Prax Wirtschaftsinform* 52(3):433–443
- Romero C, Ventura S (2007) Educational data mining: a survey from 1995 to 2005. *Expert Syst Appl* 33(1):135–146
- Schulte J, Fernandez de Mendonca P, Martinez-Maldonado R, Buckingham Shum S (2017) Large scale predictive process mining and analytics of university degree course data. *Proc. 7th International Learning Analytics & Knowledge Conference (LAK 2017)*, Vancouver. ACM, New York, S 538–539
- Trčka N, Pechenizkiy M (2009) From local patterns to global models: towards domain driven educational process mining. *Proc. 9th International Conference on Intelligent Systems Design and Applications (ISDA'09)*, S 1114–1119
- Trčka N, Pechenizkiy M, van der Aalst W (2010) Process mining from educational data. In: Romero C, al (Hrsg) *Handbook of educational data mining*. CRC Press, Boca Raton, S 123–142
- Wang R, Zaiane O (2015) Discovering process in curriculum data to provide recommendations. *Proc 8th International Conference on Educational Data Mining*, Madrid, S 580–581
- Weijters A, van der Aalst W, De Medeiros A (2006) Process mining with the heuristics miner-algorithm. *Tech. Rep. WP, Vol. 166*. Technische Universität, Eindhoven, S 1–34
- Zadeh L (1988) Fuzzy Logic. *Computer (Long Beach Calif)* 21(4):83–93